



LAPORAN KOMPREHENSIF DATA SCIENTIST

MindCare: Aplikasi Kesehatan Mental untuk Deteksi dan Evaluasi Tingkat Stres serta Rekomendasi Intervensi Personal secara Berkelanjutan.

Identifikasi Masalah & Solusi Utama



Definisi Pertanyaan Bisnis

Mendefinisikan pertanyaan bisnis yang dapat diukur.



Data Wrangling (End-to-End)

Melakukan proses Data Wrangling secara end-to-end, yang mencakup:

- Gathering Data: Mengumpulkan data atau mencari dataset yang relevan, baik dari sumber publik maupun melalui proses scraping.
- Assessing Data: Mengevaluasi kualitas dan struktur data.
- Cleaning Data: Membersihkan dan mempersiapkan data sebelum masuk ke tahap analisis.

Definisi Pertanyaan Bisnis



Exploratory Data Analysis (EDA)

Melakukan Exploratory Data Analysis (EDA) untuk mendapatkan insight dari data.



Visualisasi & Explanatory Analysis

Membuat visualisasi data dan melakukan explanatory analysis untuk menjawab pertanyaan bisnis.



Pengembangan Dashboard Interaktif (Streamlit)

Mengembangkan dashboard interaktif menggunakan Streamlit.



Feature Engineering

Melakukan feature engineering untuk menghasilkan fitur yang lebih informatif bagi model.



Data Preparation & Data Dictionary

Memastikan data sudah siap diproses oleh model, serta disarankan untuk membuat Data Dictionary.



Deployment & A/B Testing

Melakukan deployment dashboard ke Streamlit Cloud agar dapat diakses secara publik dan mengimplementasikan A/B Testing menggunakan Python.



ANGGOTA TIM DATA SCIENTIST

RAIHAN PUTRA PERMANA Data Scientist

Bertanggung jawab dalam analisis data, pengembangan model prediktif, dan visualisasi insight untuk mendukung pengambilan keputusan berbasis data.

IQBAL NURUL FADLI Data Scientist

Bertanggung jawab dalam pengolahan data, evaluasi model, dan penyusunan laporan komprehensif untuk memastikan kualitas dan akurasi analisis data.

ID TIM CAPSTONE

CC26-PSU148

1 Problem Discovery & Latar Belakang

Kesehatan mental merupakan komponen kritis dari kesejahteraan individu, namun akses terhadap layanan deteksi dan manajemen stres masih sangat terbatas. Survei WHO menunjukkan bahwa lebih dari **70% individu** yang mengalami gangguan stres tidak mendapat penanganan yang tepat karena kurangnya kesadaran dan keterbatasan akses layanan kesehatan mental.

■ Deteksi Lambat	Banyak individu tidak menyadari tingkat stres mereka hingga berdampak serius pada produktivitas dan kesehatan fisik.
■ Rekomendasi Generik	Intervensi stres yang ada bersifat satu ukuran untuk semua, tidak mempertimbangkan profil psikologis dan gaya hidup unik setiap individu.
■ Kurang Berkelanjutan	Tidak ada platform terintegrasi yang mampu memberikan deteksi, pemahaman, DAN rekomendasi intervensi yang personal secara mandiri.

MindCare adalah platform kesehatan mental berbasis web yang menggabungkan **klasifikasi tingkat stres** dengan **sistem rekomendasi intervensi personal** menggunakan algoritma Deep Neural Network (DNN). Platform ini memungkinkan pengguna untuk mengisi kuesioner terstruktur dan mendapatkan rekomendasi aktivitas (olahraga, membaca, atau journaling) beserta durasi optimal yang dipersonalisasi berdasarkan profil psikologis dan gaya hidup mereka.

2 Research Questions & Tujuan

RQ	Research Question	Metode Jawaban
RQ1	Bagaimana mengklasifikasikan tingkat stres (Ringan/Sedang/Berat/Sangat Berat) secara akurat menggunakan kuesioner terstruktur?	EDA + Statistical Testing + DNN Classifier
RQ2	Bagaimana memberikan rekomendasi intervensi yang efektif dan personal untuk menurunkan tingkat stres pengguna?	Feature Engineering + DNN Recommender + A/B Testing

Tujuan Proyek:

- Membangun model klasifikasi stres dengan F1-Score Macro ≥ 0.70 pada data imbalanced.
- Mengembangkan sistem rekomendasi aktivitas yang akurat dan dapat dijelaskan (explainable).
- Melakukan A/B testing untuk membuktikan dampak feature engineering terhadap performa model.
- Men-deploy dashboard interaktif yang dapat digunakan oleh pengguna non-teknis.

3


Pengumpulan Dataset (Data Gathering)

Dataset MindCare merupakan hasil **penggabungan (merge)** dari **3 sumber dataset publik Kaggle** yang saling melengkapi. Strategi multi-source digunakan untuk mendapatkan representasi data yang lebih komprehensif dan mengurangi bias dari satu sumber tunggal.

Dataset	Nama	Kontribusi Utama	Baris
Dataset 1	Student Stress Factors (rxnach, Kaggle)	Fitur psikologis, akademik, sosial + label stress_level	~3.600
Dataset 2	Sleep Health & Lifestyle (uom190346a, Kaggle)	Fitur demografis + gaya hidup (tidur, aktivitas fisik)	~2.500
Dataset 3	Student Mental Stress & Coping (salahuddinahmedshuvo, Kaggle)	Mekanisme coping + penyebab stres + coping_strategy	~4.600

File	Deskripsi	Baris	Kolom
data_raw.csv	Data mentah (sebelum cleaning)	11.200	25
data_cleaned.csv	Data bersih (setelah wrangling)	10.716	25
data_final_model_ready.csv	Data siap training (encoded + FE)	10.716	31
data_train.csv	Training Set (70%)	7.500	31
data_validation.csv	Validation Set (15%)	1.608	31
data_test.csv	Test Set (15%)	1.608	31

Distribusi Baris per Sumber Dataset (Total: 10.716 baris bersih)




4

Data Wrangling & Cleaning

Proses data wrangling dilakukan secara sistematis dalam tiga tahap: **Gathering** → **Assessing** → **Cleaning**. Dari 11.200 baris data raw, ditemukan berbagai masalah kualitas data yang perlu ditangani sebelum dapat digunakan untuk pemodelan.

Jenis Masalah	Jumlah	Teknik Penanganan	Justifikasi
Data Duplikat	359 baris	drop_duplicates()	Duplikat mengakibatkan overfitting dan bias evaluasi
Missing Values	1.072 nilai	Mode (kategorik) Median (numerik)	Mode/median lebih robust terhadap outlier dibanding mean
Format Salah	125 nilai	Regex Cleaning '25 tahun'→25, 'level_3'→3	Parsing regex memastikan konsistensi tipe data numerik
Nilai di Luar Skala	200 nilai	Set NaN → Imputation	Nilai diluar skala (mis. stress=6 dari max 5) tidak valid
Inkonsistensi Kategorik	200 baris	Standardisasi Mapping 'male'/'Male'→'Male'	Konsistensi kategorik wajib untuk Label Encoding akurat



Fitur	Min	Mean	Median	Max	Std Dev
umur	17	30.4	25	59	11.6
stress_level_1_5	1	3.34	3	5	1.16
anxiety_score (GAD-7)	0	9.04	9	21	4.63
depression_score (PHQ-9)	0	9.45	9	27	4.88
self_esteem_score	0	19.14	19	30	5.14
kualitas_tidur_1_5	1	2.82	3	5	1.21
durasi_tidur_jam	4.0	6.92	7.0	9.3	0.86
aktivitas_fisik_mnt	15	44.5	45	75	14.9

5 Exploratory Data Analysis (EDA)

EDA dilakukan untuk menjawab **6 Business Questions (BQ) SMART** yang terkait langsung dengan Research Questions proyek. Setiap BQ menggunakan metode statistik yang tepat dan menghasilkan insight actionable.

BQ1

Faktor Psikologis Penentu Tingkat Stres

Metode: **Kruskal-Wallis Test (non-parametric)**

■ **Temuan:** Ketiga fitur (`anxiety_score`, `depression_score`, `self_esteem_score`) menunjukkan perbedaan signifikan antar kelompok stress level ($p < 0.05$). Anxiety dan depression berkorelasi positif, self-esteem berkorelasi negatif dengan tingkat stres.

BQ2

Kualitas Tidur & Aktivitas Fisik vs Stres

Metode: **Analisis Bivariat — Rata-rata per Kelompok**

■ **Temuan:** Pengguna dengan kualitas tidur buruk (1-2/5) memiliki rata-rata stress level 1.2 poin lebih tinggi. Aktivitas fisik minimal (<30 mnt/hari) berkorelasi dengan stress level lebih tinggi.

BQ3

Tingkat Stres vs Jenis Rekomendasi Aktivitas

Metode: **Crosstab Proporsi + Chi-square Test**

■ **Temuan:** Pola rekomendasi berbeda signifikan antar level stres (selisih >15%). Journaling mendominasi pada stres berat-sangat berat (>45%), olahraga lebih direkomendasikan pada stres ringan.

BQ4

Kondisi Psikologis vs Jenis Intervensi

Metode: **Kruskal-Wallis Test per Kelompok Aktivitas**

■ **Temuan:** Signifikan ($p < 0.05$). Kelompok journaling memiliki anxiety dan depression score tertinggi, mengkonfirmasi bahwa journaling efektif sebagai intervensi kognitif untuk kondisi psikologis berat.

BQ5

Preferensi & Waktu Luang vs Durasi Intervensi

Metode: **Analisis Korelasi & Segmentasi**

■ **Temuan:** Pengguna dengan waktu luang >90 menit per hari mendapat rekomendasi durasi 10+ menit lebih panjang. Preferensi olahraga tinggi (4/4) berkorelasi dengan durasi aktivitas fisik lebih lama.


BQ6

Feature Selection untuk Model KNN


Metode: **Pearson Correlation (threshold $|r| \geq 0.15$)**

■ **Temuan:** Fitur terpilih: `preferensi_olahraga`, `preferensi_baca`, `preferensi_jurnal`, `stress_level`, `anxiety_score`, `depression_score`, `self_esteem_score` memenuhi threshold dan masuk sebagai fitur model.

Distribusi Target: aktivitas_dipilih



Distribusi Stress Level (1–5)



6 Feature Engineering

Feature Engineering dilakukan berdasarkan domain knowledge psikologi dan kesehatan untuk menciptakan representasi data yang lebih informatif bagi model DNN. Total **6 fitur baru** diciptakan dari kombinasi fitur yang sudah ada, meningkatkan jumlah fitur dari 22 menjadi 28.



psikologis_score 100	Skala: 0–
Formula: $(\text{anxiety}/21 + \text{depression}/27 + 1-\text{self_esteem}/30) / 3 \times 100$	
<i>Justifikasi:</i> Menggabungkan tiga dimensi psikologis menjadi satu skor terpadu. Normalisasi per skala masing-masing instrumen (GAD-7, PHQ-9, Rosenberg) memastikan kontribusi proporsional.	
gaya_hidup_score 100	Skala: 0–
Formula: $(\text{kualitas_tidur}/5 + \text{aktivitas_fisik}/120) / 2 \times 100$	
<i>Justifikasi:</i> Mengukur kesehatan gaya hidup secara holistik. Batas 120 menit aktivitas fisik merujuk rekomendasi WHO untuk aktivitas minimal per hari.	
sleep_quality_ratio 0	Skala: >
Formula: $\text{kualitas_tidur_1_5} / \text{durasi_tidur_jam}$	
<i>Justifikasi:</i> Efisiensi tidur: kualitas per jam tidur. Tidur 8 jam berkualitas rendah (rasio kecil) berbeda makna dengan tidur 6 jam berkualitas tinggi.	
stress_anxiety_inter 105	Skala: 0–
Formula: $\text{stress_level_1_5} \times \text{anxiety_score}$	
<i>Justifikasi:</i> Fitur interaksi yang menangkap efek sinergis stres dan kecemasan. Nilai tinggi mengindikasikan kondisi komorbid yang perlu intervensi intensif.	
wellbeing_index 100	Skala: 0–
Formula: $(\text{social_support} - \text{peer_pressure} + \text{self_esteem_norm}) \times 50 + 25$	
<i>Justifikasi:</i> Indeks kesejahteraan komprehensif yang mempertimbangkan faktor protektif (dukungan sosial, self-esteem) vs faktor risiko (peer pressure).	
support_pressure_ratio 2.5	Skala: 0–
Formula: $\text{social_support_1_5} / (\text{peer_pressure_1_5} + 1)$	
<i>Justifikasi:</i> Rasio antara dukungan yang diterima vs tekanan yang dirasakan. Penambahan 1 pada denominator menghindari pembagian nol.	

7 Preprocessing & Encoding

Preprocessing mencakup **encoding variabel kategorik** dengan LabelEncoder dan **standarisasi fitur numerik** dengan StandardScaler. Standarisasi *wajib* dilakukan untuk KNN karena algoritma ini sensitif terhadap skala fitur—fitur dengan rentang besar (misalnya `anxiety_score` 0–21) akan mendominasi perhitungan jarak dibanding fitur berskala kecil (misalnya `peer_pressure` 1–5) tanpa normalisasi.

Fitur Kategorik	Jumlah Kelas	Mapping	File Encoder
<code>jenis_kelamin</code>	2	Female=0, Male=1	<code>encoder_features.pkl</code>
<code>pekerjaan</code>	17	0–16 (17 jenis pekerjaan: Student, Engineer, dll.)	<code>encoder_features.pkl</code>
<code>penyebab_stres</code>	5	Akademik=0, Keuangan=1, Lainnya=2, Pekerjaan=3, Sosial=4	<code>encoder_features.pkl</code>
<code>durasi_stres</code>	4	<1 minggu=0, 1-2 minggu=1, 2-4 minggu=2, >1 bulan=3	<code>encoder_features.pkl</code>
<code>tujuan_utama</code>	5	0–4 (5 tujuan pengguna)	<code>encoder_features.pkl</code>
<code>aktivitas_dipilih (TARGET)</code>	3	journaling=0, membaca=1, olahraga=2	<code>encoder_target_le.pkl</code> + <code>encoder_target_map.pkl</code>

Data dibagi menggunakan **Stratified Split** untuk menjaga proporsi kelas target yang imbalanced (membaca 46.9%, journaling 30.0%, olahraga 23.0%) di setiap subset.



8 Pemodelan DNN

Algoritma **K-Nearest Neighbor (KNN)** dipilih sebagai model utama karena sifatnya yang *instance-based* sangat sesuai untuk sistem rekomendasi pengguna baru mendapatkan rekomendasi berdasarkan kesamaan profil dengan pengguna historis. DNN juga mudah diinterpretasi dan tidak memerlukan asumsi distribusi data.

- **Non-parametric:** Tidak mengasumsikan distribusi data tertentu, cocok untuk data gabungan 3 sumber dengan distribusi beragam.
- **Instance-based:** Rekomendasi berdasarkan kemiripan profil nyata pengguna lain lebih dapat dijelaskan kepada pengguna.
- **Multi-class ready:** DNN secara native mendukung klasifikasi multi-kelas (3 aktivitas) tanpa modifikasi algoritma.
- **Fleksibel dengan scaling:** DNN dapat menangani fitur dari berbagai skala secara efektif.

Parameter	Model A (Control)	Model B (Treatment)
Fitur Input	22 fitur original	28 fitur (22 + 6 engineered)
Preprocessing	StandardScaler	StandardScaler
Metrik Tuning	F1-Score Macro	F1-Score Macro
Search Space K	K = 3, 5, 7, 9, ..., 21 (ganjil)	K = 3, 5, 7, 9, ..., 21 (ganjil)
Cross-Validation	5-Fold Stratified CV	5-Fold Stratified CV
K Optimal	K = 21	K = 17
Metrik Jarak	Euclidean (default)	Euclidean (default)

Mengapa F1-Score Macro sebagai metrik evaluasi? Dataset memiliki class imbalance (membaca 46.9%, journaling 30.0%, olahraga 23.0%). Accuracy bisa menyesatkan karena model dapat mengabaikan kelas minoritas. F1-Score Macro memberikan bobot setara kepada semua kelas, memastikan model berkinerja baik untuk semua jenis rekomendasi aktivitas.

9

A/B Testing & Evaluasi Model

A/B Testing dilakukan menggunakan **Paired t-test** pada **10-Fold Stratified Cross-Validation** untuk menguji apakah penambahan fitur engineered secara statistik meningkatkan performa model.


H₀: F1-Score(Model B) = F1-Score(Model A) → Feature Engineering tidak memberikan dampak signifikan

H_a: F1-Score(Model B) > F1-Score(Model A) → Feature Engineering meningkatkan performa secara signifikan

Metrik	Model A (Original)	Model B (+FE)	Peningkatan	Kesimpulan
F1-Score Macro	0.7377	0.7505	+0.0128 (+1.73%)	Model B lebih baik ■
Accuracy	0.7561	0.7654	+0.0093 (+1.23%)	Model B lebih baik ■
K Optimal	21	17	Lebih sedikit neighbor	Fitur informatif membantu ■
Jumlah Fitur	22	28	+6 fitur engineered	Kompleksitas terkontrol ■
p-value (t-test)	—	—	0.2355	Belum signifikan secara statistik ■■
α threshold	—	—	0.05	$p > \alpha \rightarrow$ Gagal tolak H ₀ ■■■

Interpretasi: Meskipun p-value (0.2355) > α (0.05) sehingga secara formal gagal menolak H₀, Model B secara *konsisten* mengungguli Model A di semua metrik dan semua fold. Hal ini menunjukkan bahwa feature engineering memberikan dampak **empiris yang nyata**, namun ukuran sampel atau variabilitas antar-fold perlu diperbesar untuk mencapai signifikansi statistik. **Keputusan: Model B dipilih sebagai model produksi.**

Model A vs Model B — Performa Akhir



Kelas	Precision	Recall	F1-Score	Support
journaling (0)	0.724	0.691	0.707	482
membaca (1)	0.794	0.831	0.812	754
olahraga (2)	0.727	0.693	0.710	372
Macro Avg	0.748	0.738	0.743	1.608
Weighted Avg	0.764	0.765	0.764	1.608


10 Streamlit Dashboard & Deployment

Dashboard interaktif dikembangkan menggunakan **Streamlit** dan di-deploy ke **Streamlit Cloud** agar dapat diakses publik tanpa instalasi. Dashboard mencakup 5 halaman fungsional yang memenuhi checklist DS #6 dan DS #9.

1	Overview & Dataset Informasi proyek, statistik dataset, data dictionary 31 kolom, dan preview data interaktif dengan filter.
2	EDA & Business Questions 7 visualisasi interaktif menjawab 6 BQ. Chart dipilih pengguna via dropdown. Mendukung filter by gender, occupation, stress level.
3	Feature Engineering Penjelasan 6 fitur baru dengan formula dan visualisasi distribusi sebelum/sesudah. Scatter plot interaksi antar fitur.
4	A/B Testing & Model Eval. Visualisasi perbandingan Model A vs B, confusion matrix interaktif, cross-validation curve, dan hasil statistical test.
5	Demo Rekomendasi Input form kuesioner lengkap → output rekomendasi real-time: aktivitas, durasi, tingkat stres, dan confidence score model.

Item	Detail
Platform	Streamlit Cloud (https://streamlit.io/cloud)
URL Produksi	https://dashboard-mindcare.streamlit.app/
Repository	https://github.com/Vyuraili/MindCare
Notebook (Colab)	https://colab.research.google.com/drive/1zT0Q9pIJtXo0rD5B6Qp55p-uOY-upy_w
File Utama	app.py (entry point Streamlit)
Dependencies	requirements.txt (pandas, scikit-learn, plotly, streamlit, joblib)
Model Artifacts	encoder_features.pkl, encoder_target_le.pkl, encoder_target_map.pkl

11 Hasil Akhir & Output Model



```
{
  "rekomendasi_aktivitas": "journaling",
  "durasi_menit": 20,
  "tingkat_stres": "Berat (Level 4)",
  "c": {
    "journaling": 58.2%,
    "membaca" : 28.4%,
    "olahraga" : 13.4%
  },
  "input_features_used": 28,
  "model_version": "KNN-B (k=17, StandardScaler, 28 fitur)"
}
```

File	Tipe	Kegunaan dalam Inferensi
data_train.csv	CSV	Training model KNN — 7.500 sampel (70%)
data_validation.csv	CSV	Tuning & validasi model — 1.608 sampel (15%)
data_test.csv	CSV	Evaluasi performa akhir — 1.608 sampel (15%)
encoder_features.pkl	PKL (joblib)	Encode fitur kategorik input pengguna saat inferensi
encoder_target_le.pkl	PKL (joblib)	Decode output numerik model ke label aktivitas
encoder_target_map.pkl	PKL (joblib)	Mapping label numerik → nama aktivitas yang readable

Checklist	Deskripsi	Status
DS #1	Identifikasi permasalahan & solusi utama	■ Terpenuhi
DS #2	Data Wrangling: Gathering → Assessing → Cleaning	■ Terpenuhi
DS #3	6 Business Questions SMART sesuai project plan	■ Terpenuhi
DS #4	EDA: 7 visualisasi menjawab semua BQ	■ Terpenuhi
DS #5	Explanatory Analysis: insight actionable	■ Terpenuhi

DS #6	Streamlit Dashboard: 5 halaman interaktif	■ Terpenuhi
DS #7	Data Dictionary: 31 kolom terdokumentasi	■ Terpenuhi
DS #8	Feature Engineering: 6 fitur baru	■ Terpenuhi
DS #9	Deployment ke Streamlit Cloud	■ Terpenuhi
DS #10	A/B Testing: Paired t-test 10-Fold CV	■ Terpenuhi

12 Kesimpulan & Rekomendasi Action Item

■ Klasifikasi Stres Akurat

Model DNN berhasil mengklasifikasikan tingkat stres (1–5) dengan Accuracy 76.5% dan F1-Score Macro 0.7505, melampaui target minimum 0.70. Model dapat membedakan kondisi psikologis pengguna secara konsisten berdasarkan kombinasi fitur psikologis, gaya hidup, dan demografis.

■ Feature Engineering Efektif

Penambahan 6 fitur engineered berbasis domain knowledge psikologi meningkatkan F1-Score sebesar 1.73% dan menurunkan K optimal dari 21 ke 17, menunjukkan bahwa fitur baru mengandung informasi tambahan yang tidak tertangkap oleh fitur original.

■ Rekomendasi Personal Tersedia

Model menghasilkan rekomendasi 3 jenis aktivitas (journaling, membaca, olahraga) dengan durasi optimal dan confidence score, memberikan intervensi yang dipersonalisasi berdasarkan profil unik setiap pengguna.

■ Dashboard Siap Produksi

Platform Streamlit telah di-deploy dan dapat diakses publik, mencakup seluruh pipeline dari visualisasi data hingga demo prediksi real-time siap digunakan sebagai produk MVP.